

Москва, 2026 г.

СОДЕРЖАНИЕ

1	Цель работы	2
2	Теоретические сведения	3
3	Исходные данные	4
4	Вычисление собственных значений и собственных векторов . . .	5
5	Доля объяснённой дисперсии	6
6	Главные компоненты	8
7	Вывод	9

1 Цель работы

Изучить метод главных компонент и применить его к заданной ковариационной матрице: определить собственные значения и собственные векторы, сформировать главные компоненты, оценить их вклад в суммарную дисперсию и определить число компонент, достаточное для сохранения основной части информации.

2 Теоретические сведения

Метод главных компонент относится к методам проекции признаков. Исходное пространство размерности p преобразуется в новое пространство, координаты которого являются линейными комбинациями исходных признаков. Главные компоненты выбираются так, чтобы первая компонента обеспечивала максимальную дисперсию проекции, а каждая следующая была некоррелирована с предыдущими и имела максимально возможную оставшуюся дисперсию.

Пусть центрированный вектор исходных признаков имеет вид

$$\mathbf{x} = (x^{(1)}, x^{(2)}, \dots, x^{(p)})^T,$$

а его ковариационная матрица равна Σ . Главная компонента записывается как

$$y^{(i)} = \mathbf{l}_i^T \mathbf{x}.$$

Вектор $\mathbf{l}_i$ является собственным вектором ковариационной матрицы и удовлетворяет уравнению

$$(\Sigma - \lambda_i I) \mathbf{l}_i = 0.$$

Собственные значения упорядочиваются по убыванию:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p.$$

Дисперсия i -й главной компоненты равна соответствующему собственному значению λ_i .

Относительная накопленная доля дисперсии для первых p' компонент определяется выражением

$$q(p') = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_{p'}}{\lambda_1 + \lambda_2 + \dots + \lambda_p}.$$

По этой величине выбирается число компонент, которое целесообразно сохранить.

3 Исходные данные

Для варианта 2 задана ковариационная матрица

$$\Sigma = \begin{pmatrix} 0.220 & 0.057 & -0.083 & -0.073 & 0.013 \\ 0.057 & 0.172 & -0.009 & -0.033 & -0.043 \\ -0.083 & -0.009 & 0.051 & 0.059 & 0.027 \\ -0.073 & -0.033 & 0.059 & 0.242 & -0.052 \\ 0.013 & -0.043 & 0.027 & -0.052 & 0.860 \end{pmatrix}.$$

Матрица симметрична, поэтому её собственные значения вещественны, а собственные векторы могут быть выбраны ортонормированными.

4 Вычисление собственных значений и собственных векторов

Собственные значения определяются из характеристического уравнения

$$\det(\Sigma - \lambda I) = 0.$$

После сортировки по убыванию получен вектор собственных значений

$$\boldsymbol{\lambda} = \begin{pmatrix} 0.867570 \\ 0.359469 \\ 0.168490 \\ 0.139669 \\ 0.009803 \end{pmatrix}.$$

Суммарная дисперсия равна сумме собственных значений:

$$\sum_{i=1}^5 \lambda_i = 1.545000.$$

Матрица нормированных собственных векторов, записанных по столбцам в порядке соответствующих собственных значений, имеет вид

$$L = \begin{pmatrix} -0.020707 & -0.638683 & -0.444250 & -0.525604 & -0.343566 \\ 0.056344 & -0.327358 & -0.531840 & 0.770598 & 0.113957 \\ -0.025646 & 0.304240 & -0.023029 & 0.251022 & -0.918280 \\ 0.079707 & 0.625291 & -0.716395 & -0.257196 & 0.152601 \\ -0.994679 & 0.037015 & -0.077692 & 0.027511 & 0.049512 \end{pmatrix}.$$

5 Доля объяснённой дисперсии

Результаты расчёта доли дисперсии каждой компоненты и накопленной доли приведены в таблице 1.

Таблица 1 – Собственные значения и доля объяснённой дисперсии

Компонента	λ_i	Доля, %	Накопленная доля, %
1	0.867570	56.15	56.15
2	0.359469	23.27	79.42
3	0.168490	10.91	90.33
4	0.139669	9.04	99.37
5	0.009803	0.63	100.00

На рисунке 1 представлен осыпной график собственных значений.




Рисунок 1 – Осыпной график собственных значений

Накопленная доля объяснённой дисперсии приведена на рисунке 2.




Рисунок 2 – Накопленная доля объяснённой дисперсии

Для сохранения не менее 90% суммарной дисперсии требуется

$$p' = 3$$

главных компоненты.

6 Главные компоненты

По найденным собственным векторам получены следующие линейные комбинации исходных центрированных признаков:

$$y_1 = -0.020707x_1 + 0.056344x_2 - 0.025646x_3 + 0.079707x_4 - 0.994679x_5$$

$$y_2 = -0.638683x_1 - 0.327358x_2 + 0.304240x_3 + 0.625291x_4 + 0.037015x_5$$

$$y_3 = -0.444250x_1 - 0.531840x_2 - 0.023029x_3 - 0.716395x_4 - 0.077692x_5$$

$$y_4 = -0.525604x_1 + 0.770598x_2 + 0.251022x_3 - 0.257196x_4 + 0.027511x_5$$

$$y_5 = -0.343566x_1 + 0.113957x_2 - 0.918280x_3 + 0.152601x_4 + 0.049512x_5$$

Первые компоненты соответствуют наибольшим собственным значениям и поэтому содержат наибольшую долю суммарного рассеяния исходных данных.

7 Вывод

В работе для ковариационной матрицы варианта 2 были найдены собственные значения и нормированные собственные векторы. На их основе сформированы пять главных компонент и вычислен вклад каждой из них в суммарную дисперсию. Анализ накопленной объяснённой дисперсии показал, что для сохранения не менее 90% суммарного рассеяния достаточно первых 3 главных компонент. Следовательно, исходное пятимерное пространство может быть сокращено до трёх измерений с сохранением основной части дисперсии данных.

ПРИЛОЖЕНИЕ 1 Программа вычислений

В листинге .1 приведена программа, вычисляющая собственные значения и собственные векторы, доли объяснённой дисперсии, уравнения главных компонент и графики.

Листинг .1 – Программа метода главных компонент для варианта 2

```
from pathlib import Path
import numpy as np
import matplotlib.pyplot as plt

BASE = Path(__file__).resolve().parents[1]
FIGURES = BASE / "figures"
GENERATED = BASE / "generated"
FIGURES.mkdir(exist_ok=True)
GENERATED.mkdir(exist_ok=True)

Sigma = np.array([
    [ 0.220, 0.057, -0.083, -0.073, 0.013],
    [ 0.057, 0.172, -0.009, -0.033, -0.043],
    [-0.083, -0.009, 0.051, 0.059, 0.027],
    [-0.073, -0.033, 0.059, 0.242, -0.052],
    [ 0.013, -0.043, 0.027, -0.052, 0.860],
])

def latex_matrix(matrix, digits=6):
    rows = []
    for row in matrix:
        rows.append(" & ".join(f"{value:.{digits}f}" for value in row))
    return "\\begin{pmatrix}" + " \\\\".join(rows) + "\\end{pmatrix}"

def latex_vector(vector, digits=6):
    return latex_matrix(np.asarray(vector).reshape(-1, 1), digits)

def component_formula(coefficients, index):
    parts = []
```

```

    for i, value in enumerate(coefficients, 1):
        sign = "+" if value >= 0 else "-"
        parts.append(f" {sign} {abs(value):.6f}x_{{{i}}}")
    expression = "".join(parts).lstrip()
    if expression.startswith("+"):
        expression = expression[1:].lstrip()
    return f"y_{{{index}}} = {expression}"

eigenvalues, eigenvectors = np.linalg.eigh(Sigma)
order = np.argsort(eigenvalues)[::-1]
eigenvalues = eigenvalues[order]
eigenvectors = eigenvectors[:, order]

explained = eigenvalues / eigenvalues.sum()
cumulative = np.cumsum(explained)
k90 = int(np.argmax(cumulative >= 0.90) + 1)

plt.figure(figsize=(7, 5))
plt.plot(range(1, 6), eigenvalues, marker="o")
plt.xlabel("Principal component number")
plt.ylabel("Eigenvalue")
plt.title("Scree plot")
plt.grid(True)
plt.tight_layout()
plt.savefig(FIGURES / "scree.png", dpi=180)
plt.close()

plt.figure(figsize=(7, 5))
plt.plot(range(1, 6), cumulative * 100.0, marker="o")
plt.axhline(90.0, linestyle="--")
plt.xlabel("Number of principal components")
plt.ylabel("Cumulative explained variance, %")
plt.title("Cumulative explained variance")
plt.grid(True)
plt.tight_layout()
plt.savefig(FIGURES / "cumulative.png", dpi=180)
plt.close()

```

```

rows = []
for i in range(5):
    rows.append(
        f"{i + 1} & {eigenvalues[i]:.6f} & {explained[i] * 100:.2f} & {
            cumulative[i] * 100:.2f} \\\\"
        )
variance_table = "\n".join(rows)

components = []
for i in range(5):
    components.append("\\[" + component_formula(eigenvectors[:, i], i +
        1) + "\\]")
component_text = "\n".join(components)

results = f"""% Auto-generated by code/task2_pca_variant2.py
\\newcommand{{\\CovarianceMatrix}}{{\\latex_matrix(Sigma, 3)}}}
\\newcommand{{\\EigenvaluesVector}}{{\\latex_vector(eigenvalues, 6)}}}
\\newcommand{{\\EigenvaluesMatrix}}{{\\latex_matrix(eigenvalues, 6)}}}
\\newcommand{{\\TotalVariance}}{{{eigenvalues.sum():.6f}}}
\\newcommand{{\\KForNinety}}{{{k90}}}
\\newcommand{{\\VarianceRows}}{{{
{variance_table}
}}}
\\newcommand{{\\PrincipalComponents}}{{{
{component_text}
}}}
"""

(GENERATED / "results.tex").write_text(results, encoding="utf-8")

summary = "Covariance matrix:\n" + str(Sigma)
summary += "\n\nEigenvalues:\n" + str(eigenvalues)
summary += "\n\nEigenvalues (columns):\n" + str(eigenvectors)
summary += "\n\nExplained variance:\n" + str(explained)
summary += "\n\nCumulative explained variance:\n" + str(cumulative)
summary += f"\n\nComponents for >=90%: {k90}\n"
(GENERATED / "results.txt").write_text(summary, encoding="utf-8")

```

```
print("Generated figures and generated/results.tex")
```