



Министерство науки и высшего образования Российской Федерации  
Федеральное государственное автономное образовательное  
учреждение высшего образования  
«Московский государственный технический университет  
имени Н. Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления» (ИУ)  
КАФЕДРА «Информационная безопасность» (ИУ8)

## Отчёт

### по научно-исследовательской работе студента

на тему Анализ методов формирования и классификации сетевого трафика с  
использованием машинного обучения

ФИО студента: Бочкарев Михаил Александрович

Группа: ИУ8-13М

Специальность:

Специализация:

Научный руководитель НИРС: Тутова Наталья Владимировна

|                   |       |         |                                   |
|-------------------|-------|---------|-----------------------------------|
| Работа выполнена: | _____ | _____   | Бочкарев М. А.<br>(И. О. Фамилия) |
|                   | Дата  | Подпись |                                   |
| Допуск к защите:  | _____ | _____   | Тутова Н.В.<br>(И. О. Фамилия)    |
|                   | Дата  | Подпись |                                   |

Дата защиты НИРС: \_\_\_\_\_

Результаты защиты: \_\_\_\_\_

Москва, 2026 г.

## РЕФЕРАТ

Отчёт содержит 39 стр., 2 рис., 5 табл., 25 источн.

**Ключевые слова:** СЕТЕВОЙ ТРАФИК, КЛАССИФИКАЦИЯ ТРАФИКА, МАШИННОЕ ОБУЧЕНИЕ, НАБОР ДАННЫХ, РСАР, АВТОМАТИЧЕСКАЯ РАЗМЕТКА, СТАТИСТИЧЕСКИЕ ПРИЗНАКИ, ВРЕМЕННОЕ ОКНО.

Объект исследования — сетевой трафик информационных систем. Предмет исследования — методы формирования, представления, разметки и последующей классификации сетевого трафика с применением технологий машинного обучения. Цель работы состоит в анализе существующих подходов к получению размеченных наборов трафика и формировании требований к дальнейшему экспериментальному исследованию.

Рассмотрены пассивный сбор реального трафика, открытые наборы данных, синтетическое и сценарное формирование. Для их сопоставления использованы критерии управляемости, воспроизводимости, достоверности эталонных меток, реалистичности и масштабируемости. Обосновано применение управляемого сценарного стенда с автоматической временной разметкой. Проанализированы пакетное, потоковое и оконное представления; в качестве единицы анализа принято фиксированное окно длительностью 1 с. Выполнен обзор методов машинного обучения и определены показатели для их экспериментальной оценки. Сформулированы требования к стенду, обеспечивающему воспроизводимое получение РСАР, метаданных и матрицы статистических признаков.

## СОДЕРЖАНИЕ

|                                                                                 |    |
|---------------------------------------------------------------------------------|----|
| РЕФЕРАТ . . . . .                                                               | 1  |
| ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ . . . . .                                     | 4  |
| ВВЕДЕНИЕ . . . . .                                                              | 5  |
| 1 Сетевой трафик как объект анализа и классификации . . . . .                   | 7  |
| 1.1 Понятие и уровни представления сетевого трафика . . . . .                   | 7  |
| 1.2 Основные характеристики сетевого трафика . . . . .                          | 8  |
| 1.3 Задачи классификации сетевого трафика . . . . .                             | 8  |
| 1.4 Наблюдаемость классов и ограничения постановки задачи . . . . .             | 9  |
| 1.5 Особенности сетевого трафика как данных машинного обучения . . . . .        | 10 |
| 2 Анализ методов формирования и разметки наборов сетевого трафика . . . . .     | 12 |
| 2.1 Пассивный сбор реального сетевого трафика . . . . .                         | 12 |
| 2.2 Использование открытых наборов данных . . . . .                             | 12 |
| 2.3 Условия сопоставимости наборов сетевого трафика . . . . .                   | 14 |
| 2.4 Синтетическое формирование сетевого трафика . . . . .                       | 15 |
| 2.5 Сценарное формирование трафика . . . . .                                    | 15 |
| 2.6 Репрезентативность и вариативность сценарного трафика . . . . .             | 16 |
| 2.7 Критерии анализа методов формирования данных . . . . .                      | 17 |
| 2.8 Методы разметки сетевого трафика . . . . .                                  | 18 |
| 2.9 Неопределённость временных границ и проверка разметки . . . . .             | 19 |
| 3 Анализ способов представления сетевого трафика . . . . .                      | 20 |
| 3.1 Пакетное представление . . . . .                                            | 20 |
| 3.2 Потокное представление . . . . .                                            | 20 |
| 3.3 Оконное представление . . . . .                                             | 20 |
| 3.4 Критерии сравнения способов представления . . . . .                         | 21 |
| 3.5 Выбор временной дискретизации . . . . .                                     | 22 |
| 3.6 Контроль качества исходной записи и временных окон . . . . .                | 23 |
| 3.7 Представление трафика в виде матрицы статистических признаков . . . . .     | 24 |
| 3.8 Интерпретация признаков секундного окна . . . . .                           | 25 |
| 4 Обзор методов машинного обучения для классификации сетевого трафика . . . . . | 27 |
| 4.1 Постановка задачи обучения . . . . .                                        | 27 |
| 4.2 Обзор семейств методов машинного обучения . . . . .                         | 27 |
| 4.3 Критерии оценки качества классификации . . . . .                            | 29 |
| 4.4 Разделение данных и интерпретация результатов оценки . . . . .              | 30 |
| 4.5 Анализ ошибок и устойчивости классификатора . . . . .                       | 31 |
| 4.6 Ограничения теоретического выбора алгоритма . . . . .                       | 32 |
| 5 Требования к формированию и анализу набора сетевого трафика . . . . .         | 33 |
| 5.1 Требования к программному стенду . . . . .                                  | 33 |
| 5.2 Требования к структуре набора данных . . . . .                              | 34 |

|                                            |                                                                 |    |
|--------------------------------------------|-----------------------------------------------------------------|----|
| 5.3                                        | Документирование процедуры формирования набора данных . . . . . | 34 |
| 5.4                                        | Ограничения и условия применения результатов . . . . .          | 35 |
| ЗАКЛЮЧЕНИЕ . . . . .                       |                                                                 | 36 |
| СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ . . . . . |                                                                 | 37 |

## **ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ**

DPI — Deep Packet Inspection — глубокий анализ содержимого пакетов

IDS — Intrusion Detection System — система обнаружения вторжений

IP — Internet Protocol

IPFIX — IP Flow Information Export

k-NN — k-Nearest Neighbors — метод k ближайших соседей

ML — Machine Learning — машинное обучение

PCAP — Packet Capture — формат хранения захваченных сетевых пакетов

QoS — Quality of Service — качество обслуживания

RF — Random Forest — случайный лес

SVM — Support Vector Machine — метод опорных векторов

TCP — Transmission Control Protocol

TLS — Transport Layer Security

UDP — User Datagram Protocol

## ВВЕДЕНИЕ

Современная информационная инфраструктура опирается на постоянный обмен данными между пользовательскими приложениями, серверными компонентами, облачными платформами и сетевыми службами. Для администратора сети сам факт передачи пакетов недостаточен: необходимо понимать характер взаимодействия, различать типы приложений и сервисов, оценивать изменение интенсивности обмена и обнаруживать режимы, отличающиеся от ожидаемого поведения. Поэтому классификация сетевого трафика является не отдельной узкой задачей, а одним из базовых механизмов сетевого мониторинга, управления качеством обслуживания и информационной безопасности. В обзорных работах по классификации IP-трафика подчёркивается переход от простых правил по номерам портов и анализу полезной нагрузки к статистическим и машинно-обучаемым методам, использующим наблюдаемые характеристики потоков [1, 2].

Применение машинного обучения позволяет рассматривать задачу классификации как построение отображения из признакового пространства в пространство классов. При таком подходе качество результата определяется не только выбранным алгоритмом. Не менее важны способ формирования исходных данных, корректность разметки, единообразие процедуры выделения признаков, отсутствие утечки между обучающей и контрольной выборками и соответствие данных реальным условиям применения. Ошибка на этапе подготовки набора данных способна привести к высокой формальной точности при эксперименте и низкой переносимости модели в рабочую среду. Поэтому анализ методов формирования данных должен предшествовать сравнительному исследованию алгоритмов классификации.

Особую проблему представляет получение достоверных меток классов. При пассивном захвате реального трафика оператор часто не располагает полной информацией о том, какое именно действие пользователя или программного процесса сформировало каждый поток. Ручная разметка требует значительных затрат и может быть субъективной, а правила на основе портов или сигнатур наследуют ограничения тех же методов, которые классификатор должен заменить. В исследованиях используются контролируемые стенды, профили поведения и сценарные генераторы, благодаря которым момент возникновения определённого режима известен заранее; такой подход применялся, например, при создании современных наборов CICIDS2017 и CSE-CIC-IDS2018 [3, 4].

При анализе методов классификации необходимо учитывать взаимосвязь между способом формирования трафика, процедурой разметки и признаковым представлением. Изменение любого из этих компонентов влияет на состав выборки и сопоставимость результатов. Поэтому выбор алгоритма классификации рассматривается в контексте требований к исходным данным и условиям их получения. Сравнение алгоритмов имеет смысл при использовании единой схемы признаков, одинаковых правил разделения выборки и заранее определённых показателей качества.

Цель исследования состоит в анализе методов формирования и классификации сетевого трафика с использованием машинного обучения и обосновании требований к получению данных для такой классификации.

Для достижения поставленной цели решаются следующие задачи:

- 1) охарактеризовать сетевой трафик как объект классификации и определить особенности его представления в виде данных машинного обучения;
- 2) проанализировать методы получения наборов сетевого трафика и способы формирования эталонных меток классов;
- 3) сопоставить пакетное, потоковое и оконное представления трафика и обосновать выбор единицы наблюдения;
- 4) рассмотреть группы статистических признаков сетевого трафика и принципы их расчёта для фиксированных временных окон;
- 5) проанализировать применимость основных семейств методов машинного обучения к задаче классификации сетевого трафика и определить показатели оценки качества;
- 6) сформулировать требования к программному стенду, структуре набора данных и условиям воспроизводимой оценки классификаторов.

Объект исследования — сетевой трафик информационных систем. Предмет исследования — методы его формирования, представления, разметки и классификации с применением машинного обучения.

# 1 Сетевой трафик как объект анализа и классификации

## 1.1 Понятие и уровни представления сетевого трафика

Сетевой трафик можно определить как совокупность передаваемых через сеть данных и сопутствующей служебной информации, наблюдаемой на выбранном участке инфраструктуры за определённый интервал времени. На физическом и канальном уровнях эта совокупность представлена кадрами, на сетевом уровне — IP-пакетами, на транспортном — сегментами TCP или датаграммами UDP. Для задач анализа важен не только состав заголовка отдельного пакета, но и контекст: направление передачи, последовательность пакетов, принадлежность к соединению, интервалы между событиями и изменение интенсивности во времени. TCP определяет состояние соединения и использует управляющие флаги для установления и завершения сеанса [5], тогда как UDP не создаёт соединения и предоставляет датаграммную передачу с минимальной служебной логикой [6].

Под сетевым потоком обычно понимают набор пакетов, объединённых общими атрибутами. На практике широко используется пятикомпонентный ключ: адрес источника, адрес назначения, порт источника, порт назначения и транспортный протокол. В зависимости от задачи поток может быть однонаправленным или двунаправленным, а также разделяться по тайм-ауту бездействия. Протокол IPFIX формализует экспорт сведений о потоках и допускает передачу различных информационных элементов, характеризующих сетевое взаимодействие [7]. Потокковое представление удобно тем, что переводит большое число пакетов в существенно меньшее число объектов, каждому из которых можно сопоставить длительность, объём, число пакетов, распределение размеров и временные характеристики.

Уровень представления определяет, какие закономерности доступны классификатору. Пакетное представление сохраняет детали протокола, потокковое — структуру отдельного взаимодействия, оконное — динамику активности субъекта или участка сети. Эти уровни не исключают друг друга. Оконный вектор может включать статистики, рассчитанные по пакетам и потокам одновременно: количество пакетов, число уникальных потоков, количество новых TCP-соединений, средний размер пакета, отношение трафика по направлениям. Поэтому выбор окна не означает отказа от потокковой информации; он задаёт регулярный временной масштаб, на котором такая информация агрегируется.

Для задач машинного обучения особенно важно формализовать отображение от сырого трафика к объектам выборки. Если исходная запись обозначена как последовательность пакетов  $P=\{p_1, p_2, \dots, p_k\}$ , то функция преобразования должна сформировать объект  $x_i$  из подмножества пакетов, относящегося к выбранной единице анализа. Результатом является вектор числовых или категориальных характеристик. Последовательность применения такого преобразования должна быть одинаковой для обучающих данных и рабочего режима. Иначе возникает расхождение распределений: модель обучается на признаках, рассчитанных одним способом, а при эксплуатации получает значения с иной семантикой.

## 1.2 Основные характеристики сетевого трафика

Характеристики сетевого трафика условно разделяются на несколько групп. Объёмные признаки описывают количество переданных данных: число пакетов и байтов, скорость передачи, средний и максимальный размер пакета. Они позволяют различать малую фоновую активность, интенсивный поток и многочисленные короткие передачи, однако сами по себе не определяют причину высокой нагрузки. Один и тот же объём за секунду может быть получен при передаче большого файла или при большом числе небольших запросов, поэтому объёмные показатели должны использоваться совместно с другими характеристиками.

Временные характеристики описывают расположение событий во времени. К ним относятся межпакетные интервалы, длительность потока, частота появления соединений, дисперсия и квантили задержек. Подобные признаки активно используются в классификации зашифрованного трафика, поскольку шифрование скрывает содержимое, но не полностью устраняет временной рисунок взаимодействия. Исследования VPN и зашифрованного трафика демонстрируют возможность выделения классов по характеристикам длительности, направлению и временному распределению пакетов [8]. При этом временные признаки особенно чувствительны к способу захвата, буферизации и выбранному масштабу агрегации.

Протокольные характеристики связаны с заголовками пакетов. Для TCP информативными могут быть количества SYN, FIN и RST, доля пакетов с PSH, число начатых и завершённых соединений. Эти показатели имеют понятную интерпретацию. Например, увеличение количества SYN относительно обычного уровня отражает рост числа попыток установить соединение; RST может характеризовать отклонённые или аварийно завершённые взаимодействия. Однако фиксированный порог по одному флагу редко универсален. Машинное обучение интересно тем, что может учитывать сочетания протокольных и статистических признаков, а не только отдельно заданные правила.

Направленные признаки разделяют обмен от клиента к серверу и от сервера к клиенту. Это позволяет различать режимы, имеющие похожий суммарный объём, но разную структуру. Запросно-ответное взаимодействие может содержать множество небольших клиентских сообщений и более крупные ответы, тогда как загрузка файла характеризуется преобладанием байтов в направлении клиента. Направленные отношения полезны и потому, что абсолютные значения интенсивности могут меняться между экспериментами, а относительная структура взаимодействия сохраняется стабильнее.

## 1.3 Задачи классификации сетевого трафика

Термин «классификация сетевого трафика» используется для нескольких близких, но не тождественных задач. Классом может быть транспортный или прикладной протокол, конкретное приложение, тип сервиса, категория пользовательской активности либо состояние безопасности. В работах по ранней классификации значительное внимание уделялось иденти-

фикации приложений: веб, почта, передача файлов, одноранговые сети, мультимедиа [1, 2, 9]. Современные исследования дополнительно рассматривают распознавание зашифрованных приложений, мобильных сервисов и типов атак [10]. Следовательно, метод подготовки данных должен исходить из того, какая семантика вкладывается в метку.

В задачах информационной безопасности распространено бинарное разделение на нормальный и аномальный трафик. Такая постановка упрощает принятие решения, но не объясняет характер аномалии. Для практического анализа полезна многоклассовая классификация, в которой нормальная активность является одним классом, а различные типы отклоняющегося поведения представлены отдельными метками. CICIDS2017, например, содержит benign-трафик и несколько категорий атак, а UNSW-NB15 включает девять типов атак наряду с нормальным трафиком [11, 3].

Многоклассовая постановка предъявляет более высокие требования к данным. Необходимо обеспечить, чтобы каждый класс был представлен достаточным количеством независимых экспериментов и чтобы различия между классами происходили из исследуемого поведения, а не из случайных особенностей сенсора. Если один класс записан в другой день, на другом интерфейсе или с иными настройками захвата, модель может использовать эти побочные признаки. Поэтому управляемый сенсор должен стремиться изменять только параметры самого сценария при сохранении одинаковой процедуры регистрации.

В рассматриваемой постановке объектом классификации служит статистическое состояние трафика на фиксированном временном интервале, а нормальная активность и виды отклонений образуют различные классы. Состав классов и выбор алгоритма требуют эмпирической проверки на размеченных данных. Представленные ниже требования направлены на обеспечение сопоставимости таких данных и исключение систематических искажений при их анализе.

#### **1.4 Наблюдаемость классов и ограничения постановки задачи**

Метка класса должна обозначать свойство, которое может быть установлено из условий проведения эксперимента. Наличие в журнале записи о пользовательском действии не означает, что все его последствия доступны в сетевой трассе: часть операций выполняется локально, а передаваемые пакеты могут содержать одновременно служебный и прикладной обмен. Поэтому единица разметки определяется заранее. Для окна длительностью 1 с метка характеризует режим сетевого взаимодействия в указанном интервале, а не отдельный пакет и не намерение пользователя. Такое определение ограничивает интерпретацию прогноза и позволяет проверять его на уровне наблюдений, сформированных одинаковым способом.

Состав классов должен исключать неоднозначность правил назначения меток. Если два сценария могут выполняться одновременно, окно может относиться к нескольким режимам. Присвоение ему единственной метки по приоритету без явного правила превращает многоклассовую задачу в зависимую от произвольного решения разметчика. Возможные способы устранения неоднозначности включают раздельное выполнение сценариев, выделение

составного класса либо переход к многометочной постановке. При ограниченном объёме данных отдельное выполнение упрощает проверку происхождения классов, однако уменьшает сходство с сетью, в которой одновременно действуют несколько приложений. Этот компромисс необходимо учитывать при определении области применимости результатов.

Класс нормальной активности также нуждается в операционном определении. Он не равнозначен отсутствию пакетов: допустимое поведение может включать интенсивную передачу файла, установление множества соединений и периодические служебные запросы. Если такие режимы отсутствуют в обучающей выборке, классификатор может ошибочно связывать высокую интенсивность с отклонением. Поэтому описание нормального класса должно включать перечень допустимых операций и диапазоны изменяемых параметров. Напротив, класс отклонения задаётся наблюдаемым режимом, а не одним пороговым значением статистического признака, иначе модель лишь воспроизведёт заранее введённое правило.

При использовании шифрования содержание прикладных сообщений может быть недоступно наблюдателю. Тогда признаки ограничиваются характеристиками, извлекаемыми из пакетов, потоков и их временной структуры. Из совпадения таких характеристик нельзя сделать вывод о тождестве прикладного содержания двух соединений. Классификатор в данной постановке оценивает различия между наблюдаемыми режимами трафика; распознавание неизвестных классов и установление причин конкретного сетевого события выходят за пределы многоклассового обучения на фиксированном перечне меток. Это ограничение необходимо отражать при интерпретации ошибок модели и формулировании выводов о её применимости.

### **1.5 Особенности сетевого трафика как данных машинного обучения**

Сетевой трафик является временным потоком данных, а не набором независимых статических объектов. Соседние пакеты и окна часто коррелированы: они относятся к одному соединению, одной передаче файла или одной фазе сценария. Случайное перемешивание всех секундных окон и последующее разделение отдельных строк на *train* и *test* способно дать завышенную оценку, поскольку почти идентичные соседние окна одного эксперимента окажутся по обе стороны разделения. Для несмещённой оценки качества необходимо разделять данные по независимым захватам или экспериментам.

Вторая особенность — дисбаланс классов. Реальная сеть большую часть времени находится в нормальном состоянии, тогда как интересующие аномалии редки. Если механически собирать трафик в естественной пропорции, обучающая выборка может почти полностью состоять из нормальных окон. Высокая ассигаса в таком случае не означает полезного классификатора. В контролируемом стенде можно целенаправленно формировать достаточное число примеров каждого поведения, однако итоговый набор всё равно должен отражать разнообразие нормальной активности.

Ещё одна особенность — сложность получения достоверной метки. При пассивном наблюдении фиксируется сетевой обмен, однако действия породившего его процесса не всегда известны. Контролируемая генерация частично решает эту проблему: сценарий задаёт эталонную метку. Если класс всегда характеризуется одинаковой частотой передачи или размером полезной нагрузки, модель может выделить артефакт генератора. Поэтому параметры сценариев следует варьировать в допустимом диапазоне и выполнять независимые повторы.

**Выводы по разделу 1.** Сетевой трафик может быть представлен на нескольких уровнях, каждый из которых сохраняет разные свойства поведения. Для задач машинного обучения существенны не только протокольные поля, но и статистика во времени, структура соединений и направление обмена. Ключевыми рисками являются временная зависимость наблюдений, дисбаланс классов, изменение условий захвата и недостоверная разметка. Следовательно, дальнейшая методика должна обеспечивать воспроизводимый источник данных, контролируемую метку и единый алгоритм преобразования трафика в признаки.

## **2 Анализ методов формирования и разметки наборов сетевого трафика**

### **2.1 Пассивный сбор реального сетевого трафика**

Наиболее очевидный способ получить данные — пассивно наблюдать реальную сеть и сохранять проходящие пакеты. Его главное преимущество состоит в естественности: трафик формируется реальными пользователями, приложениями и протоколами, а распределение интенсивностей отражает конкретную инфраструктуру. Пассивные архивы CAIDA содержат трассы высокоскоростных магистральных каналов и используются для исследования характеристик интернет-трафика, объёмов потоков и сетевых событий [12]. Архив MAWI на протяжении многих лет публикует трассы магистральной сети WIDE [13]. Такие источники ценны для изучения фоновых закономерностей и проверки масштабируемости методов.

Одновременно пассивный сбор имеет ограничения для задачи обучения классификатора с известными классами. Наблюдатель может не иметь точной информации о приложении или пользовательском действии, а в обезличенных архивах полезная нагрузка и адреса часто удаляются или преобразуются. CAIDA, например, анонимизирует адреса и удаляет payload, что необходимо для защиты приватности, но ограничивает часть возможных способов разметки [12]. Пассивная трасса особенно неудобна, если исследователю требуется получить конкретный редкий тип поведения в заданный момент времени.

Дополнительная проблема связана с конфиденциальностью. Полные PCAP-файлы способны содержать пользовательские данные, идентификаторы и адресную информацию. Поэтому реальный корпоративный трафик часто невозможно опубликовать или передать для независимой проверки. Анонимизация снижает риск, но может удалить характеристики, необходимые для конкретного исследования. Сценарный стенд в изолированной сети позволяет сформировать данные, не содержащие внешнего пользовательского обмена, и тем самым упростить вопросы воспроизводимости и распространения.

### **2.2 Использование открытых наборов данных**

Открытые наборы данных позволяют исследователям сравнивать методы на общей выборке и не тратить время на построение собственного стенда. Исторически значимым является KDD Cup 1999, основанный на данных DARPA и сформулировавший задачу различения нормальных и вредоносных соединений [14]. Набор оказал большое влияние на исследования IDS, но позднее был критикован за большое количество повторов и особенности распределения, способные исказить оценку алгоритмов. Работа Tavallae и соавторов детально анализирует эти недостатки и предлагает NSL-KDD как более компактный вариант без части избыточных записей [14].

Набор UNSW-NB15 был сформирован в киберполигоне UNSW Canberra с использованием IXIA PerfectStorm. Он сочетает нормальную активность и синтетические атаки, содержит около 100 ГБ PCAP и девять категорий атак; из захваченного трафика были извлечены 49 признаков [11]. Существенным достоинством является наличие исходных файлов и описанной процедуры формирования. Вместе с тем набор ориентирован прежде всего на обнаружение вторжений, а состав классов и признаков может не соответствовать иной постановке задачи классификации.

CICIDS2017 развивает идею сценарного формирования: авторы создавали профили нормального поведения пользователей и запускали набор распространённых атак в течение нескольких дней. Публикуются как PCAP, так и размеченные потоки и более 80 признаков, рассчитанных CICFlowMeter [3]. Этот пример особенно важен методически: он демонстрирует ценность совместного хранения исходного трафика, описания сценария и готового признакового представления. Благодаря этому исследователь может либо использовать предоставленный CSV, либо повторно извлечь собственные признаки из PCAP.

CSE-CIC-IDS2018 масштабирует подобный подход: инфраструктура включает большое количество машин, несколько подразделений и семь групп сценариев атак; для каждого дня доступны исходные PCAP и системные журналы, а также извлечённые признаки [4]. Наличие профилей и управляемых сценариев позволяет формировать общедоступные наборы с контролируемыми эталонными метками. Однако увеличение масштаба не устраняет ограничений применимости: классы, интенсивности и единица агрегации заранее заданы авторами.

Открытые наборы позволяют анализировать методы формирования выборки и использовать независимые данные для проверки переносимости результатов при сопоставимости классов и признаков. Существенный методический интерес представляют принципы, реализованные в наборах CIC: сценарное формирование, сохранение PCAP, временная привязка событий, регистрация метаданных и отдельное извлечение признаков. Эти принципы применимы и при построении программного стенда меньшего масштаба.

В исследовании М. Д. Баженова и М. М. Бусько сопоставлены пять общедоступных наборов нормального и аномального трафика; авторы также отмечают проблему несовпадения схем признаков между наборами и формируют перечень сопоставимых характеристик [15]. Это подтверждает необходимость оценивать не только опубликованные показатели классификации, но и происхождение данных, состав признаков и правила разделения выборки.

Таблица 1 – Характеристики ряда открытых наборов сетевого трафика

| Набор           | Источник данных                | Разметка / классы             | Доступные форматы        | Ограничение применения                            |
|-----------------|--------------------------------|-------------------------------|--------------------------|---------------------------------------------------|
| KDD Cup 99      | моделируемая LAN, DARPA        | normal + intrusion            | готовые записи признаков | устаревший профиль и известные дубликаты          |
| NSL-KDD         | переработка KDD99              | normal + intrusion            | готовые записи признаков | нет исходного современного PCAP                   |
| UNSW-NB15       | киберполигон, real + synthetic | normal + 9 атак               | PCAP, Argus/Bro, CSV     | другие классы и готовая схема признаков           |
| CICIDS2017      | сценарный стенд                | benign + набор атак           | PCAP, flows, CSV         | ориентация на IDS, чужие сценарии                 |
| CSE-CIC-IDS2018 | масштабный сценарный стенд     | benign + 7 сценариев          | PCAP, logs, CSV          | высокая сложность инфраструктуры                  |
| CAIDA / MAWI    | пассивный магистральный трафик | без полной эталонной разметки | PCAP / трассы            | сложно получить метки пользовательского поведения |

### 2.3 Условия сопоставимости наборов сетевого трафика

Совпадение названий классов в двух наборах не означает совпадения правил их получения. Метка «нормальный трафик» может включать разные приложения, интенсивности и топологии сети; метка одного вида атаки может объединять несколько реализаций поведения. Перед совместным использованием данных необходимо определить соответствие классов по наблюдаемым сценариям, а не только по их текстовым названиям. Если установить такое соответствие нельзя, объединение наборов делает метку неоднородной. В этом случае внешний набор следует использовать для отдельной проверки ограниченного вопроса, сформулированного с учётом его исходной семантики.

Различаться может и единица наблюдения. В одном наборе строка соответствует соединению, в другом — временному окну, а в третьем — предварительно рассчитанному вектору без доступа к исходным пакетам. Даже при одинаковых названиях столбцов признаки могут иметь различные правила вычисления: направление потока, способ учёта повторных передач и границы временного интервала. Поэтому совместная модель требует пересчёта признаков из сопоставимых исходных записей по одной схеме либо строгого описания совпадающих полей. Простое переименование столбцов не устраняет различий в их физическом смысле.

Сопоставление опубликованных показателей качества также ограничено протоколом оценки. Результат, полученный при случайном разделении соседних окон одного захвата, нельзя непосредственно сравнивать с результатом разделения по независимым экспериментам. Дополнительно влияют доли классов, число запусков, исключение пограничных окон

и порядок настройки параметров модели. Следовательно, для корректного сравнения необходимо воспроизвести одинаковую процедуру обработки и разделения данных либо явно оговорить различия и отказаться от численного ранжирования результатов, полученных в несовместимых условиях.

Использование внешней выборки для оценки переносимости требует фиксировать, какие именно условия изменились: приложения, состав классов, сетевое оборудование, фоновая нагрузка или способ захвата. При одновременном изменении всех факторов понижение качества невозможно однозначно связать с отдельной причиной. Разделение факторов по доступным метаданным помогает определить пределы интерпретации результата. Если необходимая информация об условиях сбора отсутствует, внешний набор остаётся полезным источником примеров, но не обеспечивает строгой проверки устойчивости к конкретному изменению среды.

## **2.4 Синтетическое формирование сетевого трафика**

Синтетическое формирование предполагает программное создание пакетов, потоков или прикладных действий с заранее заданными параметрами. В простейшем случае генератор посылает сообщения фиксированного размера с заданной частотой. В более сложном — воспроизводит прикладной протокол, сессии пользователей и фоновые процессы. Главное преимущество состоит в управляемости: исследователь задаёт класс и может многократно повторить эксперимент, изменяя один параметр при неизменности остальных.

Основной риск синтетики — артефакты генератора. Если все примеры класса формируются одинаковой частотой, одинаковым размером полезной нагрузки или одним и тем же порядком действий, модель может запомнить конкретные значения. Тогда высокая точность отражает способность распознавать генератор, а не обобщать тип поведения. Для уменьшения риска параметры следует варьировать в разумных диапазонах, использовать несколько независимых запусков, добавлять разнообразную нормальную активность и по возможности формировать трафик через реальный сетевой стек и прикладные механизмы.

## **2.5 Сценарное формирование трафика**

Сценарный подход представляет эксперимент как последовательность временных фаз. Каждая фаза задаёт режим работы клиента: обычную активность либо одно из исследуемых отклонений. Сценарий определяет время начала, длительность и параметры действия. Сервер или управляющий компонент синхронизирует запуск, а подсистема захвата непрерывно записывает сетевой обмен. В результате один PCAP содержит как нормальные, так и аномальные периоды при одинаковых условиях сети и оборудования.

Ключевое преимущество сценарного подхода состоит в соответствии временных границ фаз эталонным меткам. Интервал, полностью расположенный внутри одной фазы, допускает автоматическое назначение класса. При этом метка определяется параметрами управляющего сценария независимо от признаков наблюдаемого трафика; это исключает использование оцениваемого классификатора для разметки его собственной обучающей выборки.

Сценарное формирование обеспечивает контроль условий получения трафика и допускает независимый выбор классификатора. Запись PCAP позволяет рассчитывать признаки для случайного леса, метода опорных векторов, логистической регрессии, градиентного бустинга и нейронных сетей. Для сопоставления результатов необходимы единое признаковое представление и разделение данных по независимым экспериментам.

Альтернативный способ повышения содержательности обучающего набора рассматривают Д. Д. Кононов и С. В. Исаев: при обнаружении кибератак они объединяют сведения из нескольких уровней сетевого взаимодействия и вводят сеанс как единицу агрегации [16]. Этот результат показывает, что состав исходных данных и единица наблюдения должны быть явно определены до обучения модели. В настоящей постановке единицей классификации служит временное окно, а потоковые характеристики входят в его признаки.

С. О. Иванов описывает методику создания обучающих данных из собранного трафика для распознавания аномалий протокола ICMP нейронной сетью [17]. Эта работа показывает необходимость документировать преобразование исходной записи в обучающие объекты при оценке модели.

Принцип сценарного формирования и временной разметки



Рисунок 1 – Пример сценарного формирования трафика и временной разметки

## 2.6 Репрезентативность и вариативность сценарного трафика

Управляемость эксперимента позволяет получить достоверные метки, однако сама по себе не обеспечивает репрезентативность набора данных. Если все запуски одного класса имеют одинаковую длительность, число сообщений и объём передачи, различия между классами могут определяться фиксированными настройками генератора. В контрольной выборке с теми же настройками качество окажется высоким, но при изменении параметров приложения результат может ухудшиться. Поэтому для каждого сценария следует задавать область допустимых значений: размеры передаваемых объектов, интервалы между действиями, число одновременных соединений и длительность фаз. Границы этой области должны соответствовать смыслу класса и документироваться до сбора основной серии.

Вариативность необходимо вводить так, чтобы она не изменяла эталонную семантику метки. Например, класс передачи файла может включать файлы разного размера и различную интенсивность сопутствующих сообщений. Но включение в этот класс принципиально иного сценария без изменения его определения затруднит анализ ошибок. Для каждого па-

раметра фиксируются способ выбора значений и фактически использованное значение в конкретном запуске. Такое описание позволяет разделить внутриклассовую изменчивость, обусловленную настройками сценария, и изменчивость, связанную с состоянием сетевого окружения.

Порядок запуска классов представляет отдельный источник систематического смещения. Если нормальный режим всегда записывается утром, а отклонения — после изменения конфигурации стенда, модель может опираться на сопутствующие признаки времени или окружения. Аналогичный эффект возникает, если для разных классов применяются разные версии клиента, интерфейсы захвата или точки наблюдения. Чередование сценариев и регистрация условий каждого запуска снижают вероятность такого смешения факторов. При этом случайный порядок не заменяет контроля конфигурации: изменение сетевого стека должно фиксироваться явно, чтобы его влияние можно было оценить отдельно.

Фоновая нагрузка влияет на признаки окна даже при неизменном целевом сценарии. Служебный обмен, обновления, сообщения других клиентов и `retransmission` могут увеличить число пакетов и изменить распределение интервалов. Полностью исключённый фон упрощает интерпретацию, но сужает условия применимости результатов. Методически оправдано различать серии с контролируемой фоновой активностью и серии с добавленным фоном, сохраняя одинаковые правила разметки. Такое разделение позволяет выяснять, какие характеристики устойчивы к изменению нагрузки, а какие отражают главным образом лабораторные условия.

При подготовке набора данных следует анализировать не только число окон каждого класса, но и число независимых запусков, диапазоны параметров и разнообразие сочетаний режимов. Тысячи соседних окон из одного длительного захвата не заменяют повторов эксперимента, поскольку сохраняют общую сетевую среду и связанные временные события. Структура набора должна позволять проследить происхождение каждой строки до исходного файла и параметров сценария. Принцип совместной публикации исходных трасс и описаний генерации используется и в известных сценарных наборах трафика [3, 4]; при анализе собственного стенда его следует применять с учётом выбранной единицы классификации.

## **2.7 Критерии анализа методов формирования данных**

Методы формирования данных сопоставляются по критериям, соответствующим задаче классификации. Реалистичность характеризует соответствие наблюдаемого трафика поведению приложений и сетевого стека. Управляемость отражает возможность задавать момент возникновения и интенсивность режима. Воспроизводимость характеризует повторяемость эксперимента при сопоставимых условиях. Возможность получения заданных классов имеет особое значение для редких событий.

Для рассматриваемой задачи существенны управляемость, воспроизводимость, возможность формирования заданных классов, достоверность эталонных меток и автоматическая разметка. Реалистичность трафика обеспечивается выполнением клиент-серверных операций через сетевой стек. Сценарный программный стенд предоставляет контроль условий эксперимента и происхождения меток; при этом состав фонового трафика на стенде может отличаться от состава трафика действующей сети.

Таблица 2 – Сравнение подходов к формированию данных по критериям

| Подход                      | Реалистичность | Управляемость* | Воспроизводимость* | Заданные классы* | Эталонные метки* | Авторазметка* |
|-----------------------------|----------------|----------------|--------------------|------------------|------------------|---------------|
| Пассивный реальный трафик   | ++             | –              | –                  | –                | ±                | –             |
| Готовый открытый набор      | +              | –              | ++                 | –                | +                | +             |
| Синтетическая генерация     | ± / +          | ++             | ++                 | ++               | ++               | ++            |
| Сценарный программный стенд | +              | ++             | ++                 | ++               | ++               | ++            |

Примечание — «++» означает высокое соответствие критерию, «+» — соответствие с ограничениями, «±» — частичное соответствие, «–» — низкое соответствие. Звёздочкой отмечены критерии, имеющие определяющее значение для рассматриваемой задачи.

## 2.8 Методы разметки сетевого трафика

Разметка связывает каждый объект выборки с эталонным классом. При обучении с учителем ошибка метки непосредственно становится ошибкой обучающего сигнала, поэтому качество разметки не менее важно, чем объём данных. Наиболее прямой способ — экспертная ручная разметка. Специалист анализирует журналы, пакеты и контекст приложения и назначает класс. Метод гибок, но плохо масштабируется, требует времени и допускает расхождения между экспертами.

Событийная разметка связывает сетевой обмен с внешним событием: запуском приложения, началом атаки, пользовательским действием. Она близка к сценарной, но событие может фиксироваться постфактум и с некоторой временной погрешностью. В контролируемом стенде управляющая система сама инициирует фазу и может записать точный момент начала. В таком случае метка становится частью протокола эксперимента.

Сценарная разметка особенно естественна для фиксированных временных окон. Для каждого окна проверяется, какому интервалу сценария оно принадлежит. Если окно целиком находится внутри одной фазы, ему присваивается класс фазы. Если оно пересекает границу, возможны разные стратегии: исключение, присвоение доминирующего класса или отдельная переходная метка. Для чистоты сравнительного исследования предпочтительно исключать неоднозначные окна либо проектировать границы кратко размеру окна.

Автоматическая разметка должна сохранять исходную информацию о сценарии. В CSV полезно хранить не только строковую метку, но и идентификатор эксперимента, номер окна и временные границы. Эти поля не обязательно входят в модель как признаки. Их задача — позволить восстановить происхождение строки, выполнить групповое разделение и провести аудит ошибок. Служебные поля тем самым отделяются от признакового пространства.

## 2.9 Неопределённость временных границ и проверка разметки

Формальное соответствие между сценарием и записью трафика зависит от точности временных меток. Пусть фаза  $k$  занимает полуоткрытый интервал  $[a_k, b_k)$  и имеет класс  $c_k$ , а объект классификации соответствует окну  $I_i = [t_0 + i\Delta t, t_0 + (i + 1)\Delta t)$ . Однозначная метка  $y_i = c_k$  назначается только при выполнении условия  $I_i \subseteq [a_k, b_k)$ . Если окно пересекает границу двух фаз, его исключают из обучающей выборки либо выделяют в отдельную категорию переходных наблюдений. Такое правило исключает необходимость угадывать класс по объёму переданных в окне данных.

Событие запуска действия и появление соответствующего пакета в точке захвата не всегда совпадают по времени. Задержка может возникнуть при планировании процесса, установлении соединения, буферизации, передаче по сети и записи пакета на диск. Поэтому журнал управляющего сценария должен содержать фактическое время начала и окончания действия, а не только запланированные значения. Для оценки погрешности сопоставляются временные метки события в журнале и характерных пакетов в PCAP. Если верхняя оценка рассогласования составляет  $\varepsilon$ , окно считается надёжно принадлежащим фазе только при расположении внутри интервала  $[a_k + \varepsilon, b_k - \varepsilon)$ . Значение  $\varepsilon$  необходимо определять по измерениям конкретного стенда, не задавая его произвольно.

При захвате и управлении сценарием на разных машинах дополнительно возникает рассогласование системных часов. Синхронизация времени уменьшает этот эффект, но не отменяет проверки точности после эксперимента. Для каждого запуска следует фиксировать применённый механизм синхронизации и величину наблюдаемого расхождения. Если его нельзя оценить, пограничные окна не должны получать достоверную метку автоматически. Консервативное исключение небольшой части данных предпочтительнее систематической ошибки разметки вблизи смены режимов.

Проверка корректности меток включает контроль порядка фаз, отсутствия перекрытий и пропусков в журнале, согласованности временных диапазонов с длительностью PCAP и наличия подтверждения завершения сценария. Следует также различать отсутствие пакетов в полностью захваченном окне и отсутствие сведений об окне из-за сбоя записи. В первом случае наблюдение может относиться к классу, допускающему отсутствие сетевой активности; во втором случае класс не определён. Эти ситуации необходимо отражать отдельными признаками состояния эксперимента, не используя их как входные признаки классификатора.

### **3 Анализ способов представления сетевого трафика**

#### **3.1 Пакетное представление**

Пакет является минимальной естественной единицей наблюдения при захвате сетевого трафика. В пакетном представлении один объект анализа соответствует одному кадру или сетевому пакету, а признаками служат длина, направление, протокол, значения флагов, номера портов, интервалы относительно соседних пакетов и иные доступные поля заголовка. Такое представление сохраняет максимальное временное разрешение исходной трассы и позволяет реагировать на отдельное событие практически без задержки.

Пакет остаётся первичной единицей регистрации трафика. Исходный PCAP необходимо хранить независимо от формы представления, выбранной для обучения: это обеспечивает возможность повторной агрегации при изменении длительности окна или состава признаков. Однако отдельный пакет не всегда содержит достаточный контекст для определения класса поведения.

#### **3.2 Потокковое представление**

Поток объединяет пакеты, относящиеся к одному логическому обмену. Классическое определение использует комбинацию адресов источника и назначения, портов и протокола. При двунаправленном анализе прямое и обратное направления рассматриваются как единый flow. Именно потокковое представление стало основой большого числа ранних работ по статистической классификации приложений, поскольку сокращает объём данных и формирует интерпретируемые характеристики: длительность, число пакетов, объём байтов, средний размер, направление и межпакетные интервалы [1, 2, 9].

Потокковое представление может использоваться при построении признакового пространства. Для фиксированного временного окна рассчитываются число уникальных потоков, число новых TCP-соединений, средний размер потока и распределение направлений обмена. Это сохраняет сведения о структуре потоков в пределах регулярной временной сетки и допускает классификацию в потокковом режиме.

#### **3.3 Оконное представление**

Оконное представление разбивает временную шкалу наблюдения на последовательность интервалов фиксированной длительности. Пусть длительность окна равна  $\Delta t$ , тогда  $i$ -е окно можно задать как  $W_i = [t_0 + i\Delta t, t_0 + (i+1)\Delta t)$ . Все пакеты, временная метка которых попадает в данный интервал, используются для вычисления одного вектора статистических признаков. В результате непрерывная последовательность преобразуется в регулярный ряд объектов одинаковой семантики.

Фиксированная сетка упрощает автоматическую разметку сценариев. Если границы фаз известны и совпадают с целыми границами окон, каждой строке матрицы однозначно соответствует один класс. Если окно пересекает переход между фазами, оно может быть исключено или помечено как переходное. Такая формализация значительно проще, чем попытка присваивать метку каждому пакету или каждому потоку при наличии сложного многопоточного поведения.

Важен и вопрос неполных окон. Если захват заканчивается через 0,3 секунды после начала последнего интервала, его количественные признаки нельзя напрямую сравнивать с полными секундными окнами. Нормировка к packets/s частично решает проблему, но распределения флагов и потоков остаются менее устойчивыми. Для обучающего набора предпочтительно использовать только полные интервалы либо явно хранить фактическую длительность и исключать неполные строки из основного обучения.

### 3.4 Критерии сравнения способов представления

Формы представления сопоставляются по сохранению временной динамики, компактности, пригодности для расчёта статистических признаков и возможности обработки по мере поступления пакетов. Последний критерий требует рассчитывать объект классификации без использования данных, относящихся к более позднему времени.

Пакетное представление сохраняет исходную динамику, но приводит к большому числу объектов и не описывает контекст взаимодействия в пределах одного наблюдения. Потокное представление сокращает объём данных, однако не всегда отражает поведение, распределённое между множеством соединений. Оконное представление формирует регулярную временную сетку и позволяет объединять пакетные и потоковые статистики. По совокупности рассмотренных критериев для классификации выбран оконный подход с сохранением РСАР в качестве первичного источника данных.

Таблица 3 – Сравнение способов представления сетевого трафика

| Представление | Временная динамика* | Компактность | Статистич. признаки* | Интерпретируемость* | Потоковый режим* |
|---------------|---------------------|--------------|----------------------|---------------------|------------------|
| Пакетное      | ++                  | –            | ±                    | +                   | ++               |
| Потоковое     | +                   | ++           | ++                   | ++                  | +                |
| Оконное       | ++                  | + / ++       | ++                   | ++                  | ++               |

Примечание — оценка является качественной и относится к поставленной задаче многоклассовой классификации состояния трафика; звёздочкой отмечены критичные критерии.

### 3.5 Выбор временной дискретизации

Размер окна определяет компромисс между временным разрешением и статистической устойчивостью. При  $\Delta t=0,1$  с система способна локализовать очень короткие всплески, однако при обычной фоновой активности многие интервалы будут содержать один-два пакета или оставаться пустыми. Средний inter-arrival и дисперсия в таких окнах часто не определяются устойчиво, а размер матрицы признаков увеличивается в десять раз по сравнению с секундной сеткой.

Выбор длительности не имеет универсального решения: в работе J. Koumar и соавторов по временным признакам потоков показано, что слишком большой интервал агрегации скрывает детали поведения, а слишком малый создаёт множество нулевых значений; подходящий интервал может различаться между временными рядами и меняться со временем [18]. Поэтому адаптивная длительность или подбор размера окна по данным представляют отдельное направление исследования. Для рассматриваемой задачи окно 1 с принимается как воспроизводимая рабочая настройка, а не как доказанный оптимум. Его сравнение с другими длительностями требует одинаковых независимых запусков и оценки качества классификации вместе с задержкой решения.

Интервал 1 с занимает промежуточное положение между высокой временной детализацией и устойчивостью оценки статистик. При наличии сетевой активности количество пакетов и байтов в таком окне численно совпадает с их скоростью за секунду, а число новых соединений характеризует их секундную частоту. Такая интерпретация упрощает анализ признаков пространства; достаточность статистики в отдельных малозаполненных окнах должна проверяться по фактическим данным.

Выбор одной секунды также удобен для сценарной разметки. Границы фаз можно задавать в целых секундах, а каждое полное окно однозначно относится к одному режиму. Для переходных процессов при необходимости можно исключить одно окно по обе стороны границы. Такая схема хорошо воспроизводима и не требует сложного выравнивания временных шкал.

Выбранная длительность окна  $\Delta t$  должна совпадать при обработке PCAP, расчёте статистик, построении обучающей и контрольной выборок, классификации в потоковом режиме и проверке сценариев. Если модель обучена на пятисекундных окнах, а при применении получает секундные, распределение числовых признаков изменяется. Длительность окна фиксируется в описании схемы признаков и проверяется при загрузке модели.

При фиксированной длительности окна на результат влияет положение его временной сетки. Кратковременный всплеск, полностью расположенный внутри одного интервала, формирует одно выраженное значение признака. При смещении начала сетки тот же всплеск может разделиться между двумя соседними интервалами. Следовательно, время начала первого окна должно определяться однозначным правилом относительно начала захвата или сценария. При сравнении серий необходимо использовать одно и то же правило выравнивания, иначе различия признаков частично отражают положение границ, а не свойства сетевого события.

Фиксированное окно также ограничивает разрешение коротких событий. Если режим продолжается меньше одной секунды, его пакеты смешиваются с активностью остальных частей окна. Увеличение числа признаков не восстанавливает точные временные границы события после агрегации. Поэтому выбранная секундная дискретизация соответствует задаче классификации состояния трафика по полным окнам; для локализации отдельных пакетов или событий существенно меньшей длительности требуется иной уровень анализа. Это ограничение следует учитывать при определении классов и при оценке задержки обнаружения.

Проверка устойчивости результатов к положению границ может проводиться на исходных РСАР без изменения принятого рабочего размера окна. Для нескольких фиксированных смещений временной сетки повторно рассчитываются признаки и анализируется, какие наблюдения меняют свои значения или оказываются у границы сценарной фазы. Такие наблюдения указывают на чувствительность выбранного представления к дискретизации. Использование нескольких смещений в рамках одной проверки не означает изменения базового окна в обучении: рабочая длительность остаётся равной 1 с, а расчёты со смещением служат анализом ограничений метода.

Таблица 4 – Качественная оценка вариантов длительности временного окна

| Окно  | Чувствит.<br>к коротким<br>событиям | Устойчивость<br>статистик | Задержка<br>решения | Объём<br>выборки | Пригодность<br>для работы  |
|-------|-------------------------------------|---------------------------|---------------------|------------------|----------------------------|
| 0,1 с | очень высокая                       | низкая при малом трафике  | очень низкая        | очень большой    | ограниченная               |
| 1 с   | высокая                             | достаточная               | низкая              | умеренный        | высокая                    |
| 5 с   | средняя                             | высокая                   | заметная            | малый            | средняя                    |
| 10 с  | низкая                              | высокая                   | высокая             | малый            | низкая для кратких режимов |

### 3.6 Контроль качества исходной записи и временных окон

Оконная агрегация допускает воспроизводимый расчёт признаков только при корректной исходной записи. Переполнение буфера захвата, изменение сетевого интерфейса и ошибки записи могут приводить к пропуску пакетов. В таком случае число пакетов, объём байтов и производные статистики оказываются заниженными независимо от свойств исследуемого режима. Поэтому наряду с РСАР необходимо сохранять статистику подсистемы захвата, в том числе число зарегистрированных и потерянных пакетов, если соответствующие счётчики доступны. Отсутствие счётчика потерь не следует интерпретировать как подтверждение их отсутствия.

Для каждого окна фиксируются момент начала, момент окончания, число наблюдаемых пакетов и статус полноты записи. Последнее окно захвата часто имеет меньшую длительность, чем  $\Delta t$ , и не сопоставимо с остальными по суммарным признакам; его следует исключить либо обрабатывать по отдельно определённым правилам. Аналогичное требование относится к началу записи, если захват был включён после фактического начала первой фазы сценария. Сравнение ожидаемой и фактической длительности записи позволяет выявить неполные эксперименты до построения признакововой матрицы.

Нулевое значение счётчика пакетов само по себе не означает ошибку. Для редкого трафика окно без пакетов является допустимым наблюдением, если известно, что подсистема захвата работала непрерывно. Статистики, не определённые при отсутствии пакетов, например средний размер пакета или средний межпакетный интервал, должны получать заранее заданное представление. Возможные варианты включают специальное значение с дополнительным индикатором либо заполнение после разделения выборки. Выбранное правило необходимо применять одинаково к обучающим данным и к потоковому мониторингу.

При записи трафика требуется учитывать расположение точки наблюдения. Захват на клиенте, сервере и промежуточном узле может содержать разные наборы пакетов вследствие потерь, фильтрации, служебного обмена и особенностей сетевого стека. Аппаратная разгрузка сетевого интерфейса также может изменять видимые размеры или границы сегментов. Следовательно, набор признаков должен сопровождаться описанием точки захвата и её конфигурации. Если эти условия меняются, необходимо отдельно оценивать сопоставимость записей; объединение их без проверки создаёт риск распознавания конфигурации вместо класса поведения.

### **3.7 Представление трафика в виде матрицы статистических признаков**

После оконного агрегирования набор данных можно представить матрицей  $X$  размерности  $N \times M$ , где  $N$  — число полных временных окон,  $M$  — число статистических признаков. Каждой строке соответствует метка  $y_i$ . Такое представление непосредственно совместимо с большинством классических методов машинного обучения и одновременно сохраняет связь с временной шкалой через служебные поля `experiment_id`, `window_index`, `start_time` и `end_time`.

В матрицу признаков не должны автоматически попадать все столбцы CSV. Идентификатор эксперимента, имя файла, абсолютное время или IP-адрес могут случайно коррелировать с классом и привести к `data leakage`. Если, например, один тип поведения всегда записан в отдельном файле, модель способна запомнить номер эксперимента вместо сетевой закономерности. Поэтому признаки, используемые в  $X$ , должны быть перечислены явно, а метаданные храниться отдельно для группового разделения и аудита.

Состав столбцов должен иметь фиксированную схему и версию. Для каждого признака необходимо определить название, физический смысл, единицу измерения и формулу. Если в одной версии `small_packet_ratio` означает долю пакетов до 128 байт, а в другой — до 256 байт, одинаковое имя вводит скрытую несовместимость. Номер `feature schema` должен сохраняться вместе с CSV и моделью, а загрузчик модели обязан проверять соответствие.

Единый модуль извлечения признаков должен использоваться при обработке записанного трафика и данных, поступающих в реальном времени. В первом случае входные пакеты считываются из PCAP, во втором — поступают от подсистемы захвата; алгоритм обновления статистик остаётся одинаковым. Это предотвращает расхождение между представлением обучающей выборки и признаками при применении классификатора.

Совместное хранение PCAP, CSV и метаданных обеспечивает повторяемость обработки. PCAP служит первичным источником для повторного расчёта признаков, CSV содержит рассчитанные значения, а метаданные фиксируют условия эксперимента и правила разметки. Отсутствие одного из этих компонентов затрудняет проверку результатов при изменении схемы признаков.

Матрица статистических признаков: строки — окна, столбцы — признаки

|    | x1 | x2 | x3 | x4 | x5 | x6 | y |
|----|----|----|----|----|----|----|---|
| W1 | 2  | 3  | 4  | 5  | 6  | 7  | N |
| W2 | 4  | 6  | 8  | 10 | 12 | 14 | A |
| W3 | 6  | 9  | 12 | 15 | 1  | 4  | N |
| W4 | 8  | 12 | 16 | 3  | 7  | 11 | A |
| W5 | 10 | 15 | 3  | 8  | 13 | 1  | N |
| W6 | 12 | 1  | 7  | 13 | 2  | 8  | A |

Рисунок 2 – Представление окон сетевого трафика в виде матрицы статистических признаков

### 3.8 Интерпретация признаков секундного окна

Признаки окна могут описывать интенсивность обмена, размеры пакетов, временную структуру и состояние соединений. Пусть  $P_i$  обозначает множество пакетов, зарегистрированных в окне  $I_i$  длительностью  $\Delta t = 1$  с, а  $L(p)$  — длину наблюдаемого пакета  $p$ . Тогда число пакетов  $n_i = |P_i|$  и объём переданных данных  $b_i = \sum_{p \in P_i} L(p)$  образуют базовые показатели активности. При фиксированной секундной дискретизации эти значения численно равны соответствующим скоростям в пакетах и байтах за секунду. Однако совпадение числовых значений не делает исходные счётчики независимыми признаками от их скоростей: одновременное включение обеих форм приводит к дублированию информации.

Для характеристики размеров рассчитываются среднее значение, дисперсия и квантили длины пакета. Если в окне нет пакетов, среднее и квантили математически не определены; присвоение им нуля представляет отдельное соглашение схемы признаков. Если присутствует один пакет, оценка разброса также не описывает изменчивость размеров. Поэтому при анализе таких статистик необходимо учитывать величину  $n_i$  и долю малозаполненных окон в каждом классе. Использование только усреднённого размера может скрывать сочетание многочисленных коротких сообщений и небольшого числа крупных передач, имеющих одинаковый суммарный объём.

Временную структуру можно описывать межпакетными интервалами  $\tau_j = t_{j+1} - t_j$ , вычисленными для пакетов внутри окна. Среднее, медиана и максимальное значение интервала характеризуют равномерность обмена, но при  $n_i < 2$  такие показатели отсутствуют. Межпакетные интервалы на границах соседних окон следует определять по отдельному правилу: включение интервала между последним пакетом предыдущего и первым пакетом текущего окна изменяет смысл статистики и требует хранения состояния. Для потокового применения правило вычисления должно быть одинаковым при обработке РСАР и пакетов реального времени.

Направленные статистики разделяют пакеты от клиента к серверу и в обратную сторону. Наряду с числом пакетов и объёмом байтов по каждому направлению может рассчитываться доля исходящего объёма  $r_i = b_i^{\text{out}} / (b_i^{\text{out}} + b_i^{\text{in}})$ . При нулевом знаменателе значение доли не определено, поэтому вводится согласованное правило обработки пустого окна. Направление нельзя устанавливать только по текущему IP-адресу при динамической адресации: роль клиента и сервера должна определяться условиями эксперимента и сохраняться в метаданных.

Статистики соединений включают число новых TCP-соединений, число уникальных потоков и частоты наблюдения флагов SYN, FIN и RST. Эти величины описывают структуру взаимодействия, но зависят от места захвата и от полноты регистрации пакетов. Кроме того, большое число новых соединений само по себе не доказывает наличие атаки: оно может быть вызвано легитимным режимом приложения. Интерпретация признака требует сопоставления с классом сценария и с нормальной активностью в сопоставимых условиях. Состав окончательной матрицы определяется доступностью, воспроизводимостью и устойчивостью признаков, а не максимальным числом рассчитанных столбцов.

## 4 Обзор методов машинного обучения для классификации сетевого трафика

### 4.1 Постановка задачи обучения

При наличии автоматически размеченной матрицы статистических признаков задача может быть сформулирована как обучение отображения  $f: X \rightarrow Y$ , где  $X$  — пространство векторов признаков,  $Y$  — множество классов сетевого поведения. Обучающая выборка  $D = \{(x_i, y_i)\}$  содержит пары признаков и известных меток. Модель должна по новому вектору  $x$  определить наиболее вероятный класс, не используя служебную информацию о сценарии.

Обязательным элементом является разделение данных на независимые части. При временных окнах нельзя механически перемешивать соседние строки одного эксперимента. Более корректно использовать групповое разделение: целый запуск стенда относится либо к обучению, либо к проверке. При подборе гиперпараметров дополнительно формируется *validation* или применяется групповая *cross-validation*. Итоговый *holdout* должен оставаться независимым от всех решений, принимаемых в процессе разработки.

Анализ семейств алгоритмов основан на их свойствах и требованиях к исходным данным. Без результатов испытаний на едином наборе данных невозможно установить преимущество конкретной модели. Поэтому характеристики методов рассматриваются с учётом необходимой предобработки, интерпретируемости, устойчивости к дисбалансу классов и вычислительной сложности.

### 4.2 Обзор семейств методов машинного обучения

К линейным классификаторам относится логистическая регрессия. Для бинарного случая она моделирует логарифм отношения вероятностей как линейную комбинацию признаков. Многоклассовая задача решается через *multinomial*-модель или набор бинарных классификаторов. Метод сравнительно прост, быстро обучается и даёт интерпретируемые коэффициенты, что делает его полезным базовым ориентиром при исследовании табличных данных.

Наивный байесовский классификатор использует теорему Байеса и упрощающее предположение условной независимости признаков при известном классе. В реальном сетевом трафике это предположение обычно нарушается: *packet\_count*, *total\_bytes* и число *payload*-пакетов взаимосвязаны. Тем не менее алгоритм вычислительно лёгок и может служить ориентиром, особенно при дискретных или специально преобразованных признаках.

Алгоритм *k* ближайших соседей (*k*-NN) относится к метрическим методам. При классификации нового объекта вычисляется расстояние до объектов обучающей выборки, после чего класс определяется по ближайшим соседям. Классическая работа Cover и Hart заложила теоретические основы *nearest-neighbor classification* [19]. Метод не строит сложную параметрическую модель и способен формировать нелинейные границы решения.

Дерево решений последовательно разделяет пространство признаков условиями вида  $x_j \leq \theta$ . Алгоритмы семейства ID3/C4.5 и их современные реализации выбирают разделения по информационным критериям или уменьшению неоднородности [20]. Для табличных сетевых признаков дерево привлекательно тем, что естественно моделирует нелинейные комбинации и не требует обязательного масштабирования входных столбцов.

Ансамбли объединяют предсказания нескольких базовых моделей. Random Forest строит множество деревьев по bootstrap-выборкам и случайным подмножествам признаков, после чего агрегирует их ответы. Метод предложен Breiman и получил широкое применение для табличных данных благодаря способности моделировать нелинейные зависимости и относительно слабой чувствительности к масштабам [21]. Кроме класса можно получать оценки вероятностей как долю голосов или усреднённые вероятности деревьев.

В. А. Частикова и соавторы сравнивают Random Forest с многослойным перцептроном при обнаружении вторжений на наборе UNSW-NB15 [22]. Сопоставление методов на одном наборе демонстрирует применимость обоих семейств моделей к сетевым признакам, но не определяет их относительное качество для других классов и сценариев.

Градиентный бустинг строит модели последовательно, каждая следующая исправляет ошибки предыдущего ансамбля. Классический gradient boosting machine описан Friedman [23]. Современные реализации XGBoost, LightGBM и CatBoost используют оптимизации и регуляризацию, позволяя получать сильные результаты на структурированных данных. Их преимущество и сложность одновременно состоят в большом числе гиперпараметров, влияющих на качество и время обучения.

Случайный лес пригоден в качестве базового алгоритма благодаря способности учитывать нелинейные зависимости и оценивать вероятности классов. Его применение не означает превосходства над методами других семейств: сравнительная оценка требует одинакового разделения данных и заранее установленных показателей качества.

Метод опорных векторов (SVM) ищет разделяющую гиперплоскость с максимальным зазором между классами. Использование ядер позволяет неявно переходить в пространство большей размерности и формировать нелинейные границы. Классическая работа Cortes и Vapnik описывает support-vector networks для задач классификации [24]. Для многоклассовой задачи применяются схемы one-vs-one или one-vs-rest.

Многослойный перцептрон (MLP) способен аппроксимировать нелинейные зависимости между статистическими признаками. Входной слой принимает нормированный вектор, несколько скрытых слоёв формируют внутреннее представление, выходной softmax задаёт вероятности классов. В отличие от деревьев, нейронные сети обычно требуют масштабирования признаков и более аккуратного выбора скорости обучения, архитектуры и регуляризации.

Глубокое обучение позволяет работать не только с агрегированными статистиками. CNN применяются к представлениям пакетов или последовательностей байтов, RNN/LSTM — к временным последовательностям, а более новые архитектуры используют attention. Обзоры показывают значительный интерес к deep learning для encrypted traffic classification, поскольку модель может извлекать закономерности из временных и размерных последовательностей без явного DPI [10].

Не все задачи сетевого анализа имеют заранее известные классы. Кластеризация группирует объекты по сходству и может использоваться для обнаружения ранее неизвестных типов трафика. В работах Erman и соавторов исследовалась возможность классификации приложений с помощью clustering без полного набора меток [9]. Подход полезен для разведочного анализа, но кластеры сами по себе не имеют семантического названия и требуют последующей интерпретации.

### 4.3 Критерии оценки качества классификации

Качество классификации характеризуется совокупностью показателей. Точность классификации по всей выборке (ассигасу) показывает долю правильных предсказаний, однако при дисбалансе классов она может не отражать качество распознавания редких событий. Если 95 % окон относятся к нормальной активности, классификатор, всегда предсказывающий этот класс, достигнет ассигасу 0,95, не обнаружив ни одной аномалии. Поэтому общую точность необходимо дополнять поклассовыми показателями.

Precision для класса показывает, какая доля объектов, предсказанных как этот класс, действительно к нему относится. Recall отражает, какая доля реальных объектов класса была обнаружена. F1 является гармоническим средним precision и recall. Для многоклассовой задачи macro-F1 усредняет F1 по классам с одинаковым весом и тем самым не позволяет большому NORMAL полностью скрыть слабое распознавание редкого режима.

Confusion matrix показывает направления ошибок: какой класс с каким путается. Для исследовательской работы это особенно важно, поскольку одинаковое значение macro-F1 может соответствовать различной структуре ошибок. Например, путаница двух близких аномальных режимов и массовое принятие аномалии за NORMAL имеют разную практическую интерпретацию. Матрицу следует строить на независимой test-части.

Наряду с качеством предсказаний учитываются время обучения, среднее значение и верхний квантиль времени вычисления прогноза для одного окна, объём модели в памяти и требования к предобработке. В потоковом режиме расчёт прогноза должен завершаться до поступления следующего окна; выполнимость этого ограничения устанавливается экспериментально.

Таблица 5 – Показатели оценки качества и вычислительной стоимости моделей

| Показатель                | Назначение                                | Почему недостаточно использовать отдельно     |
|---------------------------|-------------------------------------------|-----------------------------------------------|
| Accuracy                  | общая доля правильных ответов             | скрывает ошибки редких классов при дисбалансе |
| Precision по классу       | достоверность срабатываний данного класса | не показывает пропущенные объекты             |
| Recall по классу          | полнота обнаружения класса                | не учитывает число ложных срабатываний        |
| Macro-F1                  | равноправная сводная оценка классов       | не показывает направление конкретных ошибок   |
| Confusion matrix          | структура взаимных ошибок                 | не даёт одного числового ранга                |
| Время вычисления прогноза | пригодность к потоковому режиму           | ничего не говорит о качестве классификации    |

#### 4.4 Разделение данных и интерпретация результатов оценки

Независимость контрольной выборки является условием достоверной оценки классификатора. Последовательные секундные окна одного захвата могут относиться к одной передаче файла, одному соединению или одной фазе сценария. Если случайным образом распределить такие окна между обучением и контролем, модель получит в обучающей части наблюдения, близкие к контрольным по времени и параметрам окружения. Полученная оценка будет характеризовать распознавание соседних окон того же запуска, а не переносимость на независимый эксперимент. Поэтому элементом разделения служит полный запуск с единым `experiment_id`.

Групповое разделение требует представительства каждого класса в нескольких независимых запусках. Если некоторый класс встречается только в одном эксперименте, невозможно одновременно сохранить его в обучении и проверить на независимом запуске. План сбора данных должен учитывать это до формирования выборки: для каждого класса необходимы повторы с различающимися допустимыми параметрами сценария. Следует также распределять нормальную активность между запусками, а не регистрировать её в одном отдельном сеансе. Иначе классификатор может распознавать особенности сеанса вместо исследуемого поведения.

Проверочная выборка используется для настройки параметров модели и выбора порогов принятия решения, контрольная — для окончательной оценки после завершения настройки. Если при поиске гиперпараметров многократно использовать контрольные данные, информация о них косвенно влияет на итоговый выбор метода. Аналогичное ограничение относится к преобразованиям признаков: значения для стандартизации, правила заполнения

пропусков и отбор признаков определяются по обучающей части и затем без повторного обучения применяются к остальным данным. Абсолютное время, имя файла и идентификатор запуска сохраняются для аудита, но исключаются из входного вектора, если их связь с классом не является предметом исследования.

Распределение классов необходимо указывать при публикации результатов, поскольку сводные показатели зависят от состава выборки. Помимо усреднённой F1-меры приводятся поклассовые полнота и точность, матрица ошибок и число объектов каждого класса. Если один запуск содержит существенно больше окон, чем другие, итоговая оценка по всем окнам преимущественно отражает именно этот запуск. Для анализа устойчивости полезно также рассчитывать показатели отдельно по независимым экспериментам и рассматривать разброс результатов. Такой способ не заменяет итоговой оценки по всем объектам, но выявляет зависимость модели от конкретного сеанса регистрации.

Применимость полученной оценки ограничена условиями, представленными в выборке. Отличия в конфигурации сети, версиях программного обеспечения, интенсивности фоновго обмена и способе захвата могут изменить распределение признаков. Поэтому результат испытания на контролируемом стенде характеризует качество для наблюдавшихся условий. Переносимость на иные условия требует отдельной проверки на независимых запусках с явно описанным изменением окружения; её нельзя выводить только из высокой точности внутри исходной выборки.

#### **4.5 Анализ ошибок и устойчивости классификатора**

Сводное значение показателя качества не позволяет определить, какие режимы распознаются ненадёжно. Поэтому анализ результатов должен начинаться с матрицы ошибок, рассчитанной по независимой контрольной выборке. Для каждой пары истинного и предсказанного классов фиксируется число окон, а при существенном дисбалансе полезно дополнительно рассматривать доли ошибок внутри каждого истинного класса. Так можно отличить редкие ошибки при часто встречающемся режиме от систематического пропуска мало представленного отклонения. При интерпретации необходимо учитывать абсолютное число наблюдений: доля, рассчитанная по нескольким окнам, не обладает той же устойчивостью, что оценка по многочисленным независимым запускам.

Ошибки в соседних окнах одного сценария могут образовывать последовательность. Если модель не распознаёт всю фазу, причина может заключаться в недостаточной делимости класса, а не в единичном выбросе. Ошибки, сосредоточенные только у границ фаз, требуют проверки временной разметки и синхронизации часов. Ошибки, возникающие преимущественно при передаче крупных файлов или на определённом интерфейсе, могут указывать на смещение условий захвата. Поэтому для анализа каждого ошибочного прогноза следует сохранять идентификатор запуска, номер окна, истинную метку и условия сценария. Эти сведения используются при разборе ошибок, но не передаются классификатору как признаки.

Отдельным аспектом устойчивости служит реакция модели на целенаправленное изменение входных признаков. П. Э. Югай исследует влияние состязательных воздействий на k-NN, случайный лес и метод опорных векторов при обнаружении сетевых угроз [25]. Этот тип проверки выходит за рамки базового сравнения качества, но его следует учитывать при интерпретации результатов для условий противодействия активному нарушителю.

Оценка вероятностей классов требует отдельной осторожности. Высокое значение, выдаваемое моделью для выбранного класса, не обязательно означает высокую эмпирическую вероятность правильного ответа. Если предполагается применять порог уверенности либо отклонять неопределённые наблюдения, его настройка выполняется на проверочной части данных; качество после введения порога оценивается на независимой контрольной части. Неопределённый ответ представляет самостоятельный исход и должен учитываться при расчёте полноты. Без этого исключение сложных окон может искусственно улучшить показатели на оставшихся данных.

Для потоковой классификации существенна не только доля правильных окон, но и задержка обнаружения изменения режима. Односекундная сетка задаёт дискретность наблюдения, однако итоговое решение появляется после завершения окна, расчёта признаков и выполнения модели. Время обработки следует измерять отдельно от времени накопления пакетов. Если оно превышает длительность окна, система может накапливать очередь даже при приемлемом среднем времени на большинстве запусков. Поэтому верхние квантили вычислительной задержки и доля окон, обработанных в пределах установленного времени, дополняют показатели качества классификации.

#### **4.6 Ограничения теоретического выбора алгоритма**

Теоретические свойства алгоритмов позволяют определить применимость методов, но не дают основания для однозначного ранжирования без результатов эксперимента. Качество зависит от распределения классов, объёма выборки, уровня шума, корреляций и вариативности сценариев. Один и тот же метод может показывать различное качество на разных наборах данных. Следовательно, выбор модели требует сравнительного испытания в единых условиях.

Корректное сравнение методов требует заранее зафиксировать состав данных, схему выделения обучающей, проверочной и контрольной выборок, набор признаков и показатели качества. Все методы оцениваются на одинаковых независимых группах экспериментов. Настройка предобработки выполняется только по обучающим данным и применяется к остальным частям выборки без повторного подбора параметров.

**Выводы по разделу 4.** Для классификации сетевого трафика применяются линейные, метрические, древесные, ансамблевые, опорновекторные, нейросетевые методы и методы обучения без учителя. Выбор алгоритма зависит от свойств выборки и требований к обработке данных. Для оценки качества определены поклассовые точность и полнота, усреднённая по классам F1-мера, матрица ошибок, а также вычислительная стоимость классификации в потоковом режиме.

## **5 Требования к формированию и анализу набора сетевого трафика**

### **5.1 Требования к программному стенду**

На основании сопоставления методов формирования данных установлены следующие требования к программному стенду:

- стенд должен формировать сетевой трафик через реальные клиент-серверные операции, а не записывать искусственно созданные строки признаков;
- должна поддерживаться последовательность фаз с заданными длительностью, типом поведения и параметрами интенсивности;
- процесс захвата PCAP должен запускаться до сценария и продолжаться непрерывно до его завершения;
- вместе с PCAP должны сохраняться точные временные границы фаз и идентификатор независимого эксперимента;
- автоматическая разметка должна выполняться по управляющему сценарию; переходные или неполные окна необходимо исключать либо маркировать отдельно;
- длительность окна анализа фиксируется на 1 с и указывается в метаданных и параметрах модели;
- исходный PCAP должен сохраняться независимо от готового CSV, чтобы признаки можно было пересчитать;
- один и тот же модуль расчёта признаков должен использоваться при обработке PCAP и потоковом мониторинге;
- служебные поля `experiment_id`, время и параметры сценария должны быть отделены от входного вектора модели;
- должна обеспечиваться возможность нескольких независимых повторов одного сценария и последующего группового разделения данных;
- параметры окружения, версия схемы признаков и версия программного стенда должны фиксироваться в метаданных;

Воспроизводимость требует сохранения конфигурации и контроля точки захвата. Изменение сетевого интерфейса, параметров аппаратного ускорения или виртуализации может изменить наблюдаемые размеры и число пакетов. Поэтому серию экспериментов следует проводить при стабильной конфигурации, а изменения окружения фиксировать в метаданных либо выделять в отдельную серию.

Отдельное требование относится к обработке прерванных экспериментов. При остановке пользователем, потере соединения или ошибке захвата запуск помечается как незавершённый. Частичные записи сохраняются для диагностики, но в обучающую выборку включаются только эксперименты с подтверждённым завершением и полными временными окнами.

## 5.2 Требования к структуре набора данных

Для каждого независимого запуска рекомендуется хранить три связанных объекта: исходный PCAP, файл метаданных и таблицу рассчитанных признаков в формате CSV. Исходная запись позволяет повторно выполнить обработку, метаданные описывают условия эксперимента и временные границы фаз, а CSV содержит результаты конкретной версии преобразования. Связь объектов обеспечивается общим идентификатором `experiment_id`.

Метаданные должны содержать время запуска, плановую и фактическую длительность, классы и границы фаз, параметры каждого режима, идентификатор клиента, интерфейс захвата, версию программного обеспечения, длительность окна `window_sec` и версию схемы признаков `feature_schema_version`. При публикации набора данных идентификаторы участников и узлов следует обезличивать без изменения параметров, необходимых для воспроизведения эксперимента.

CSV должен содержать один объект на полное секундное окно и строковую метку класса. Дополнительно сохраняются `experiment_id` и `window_index`, но они исключаются из X. Внутри одной серии порядок и названия 28 или иного утверждённого набора статистических столбцов не меняются. Любое изменение состава признаков требует увеличения версии схемы.

Для обучения и оценки качества необходимо использовать несколько независимых запусков. Повторные эксперименты позволяют учитывать вариативность временных характеристик, размеров пакетов и поведения сетевого стека. Разделение выборки по запускам снижает риск попадания связанных наблюдений одновременно в обучающую и контрольную части. Необходимое число повторов устанавливается по результатам оценки изменчивости данных для каждого класса.

Нормальный класс должен включать различные виды допустимой активности. Если он представлен только периодами отсутствия передачи, классификатор может ошибочно отнести любую передачу файла к аномалии. Поэтому в наборе необходимо представить обмен сообщениями, загрузку и отправку файлов, периоды ожидания и другие легитимные операции. Классы отклонений следует различать по характеру поведения, а не только по абсолютному объёму байтов.

## 5.3 Документирование процедуры формирования набора данных

Воспроизводимость набора определяется возможностью восстановить последовательность операций, приведших от параметров сценария к строкам признаковой матрицы. Одного хранения файлов PCAP и CSV недостаточно, если не зафиксированы версии клиента и сервера, настройки захвата, порядок запуска действий и правила исключения окон. Для каждого эксперимента должен формироваться машинно-читаемый паспорт, содержащий идентификатор запуска, параметры окружения, временные границы фаз, исход выполнения и ссылку на соответствующий файл PCAP. Такой паспорт позволяет отделять исходные наблюдения от их производных представлений.

Процедура преобразования данных должна иметь явно определённые вход и выход. Входом служат запись пакетов и журнал сценария, выходом — набор окон с признаками, метками и служебными идентификаторами. Для каждого шага фиксируются версия программного модуля, длительность окна, точка отсчёта временной сетки, способ определения направления обмена и правило работы с переходными интервалами. Если эти параметры меняются, прежний CSV нельзя считать совместимым с новым без повторной обработки исходных записей. Версия схемы признаков тем самым относится к семантике вычислений, а не только к порядку названий столбцов.

Для контроля целостности целесообразно проверять непротиворечивость связей между объектами набора. Каждая строка признаков должна указывать на существующий эксперимент и окно, расположенное в пределах его фактической длительности. Метка окна должна соответствовать зафиксированной фазе с учётом принятого допуска для границ. Число обработанных окон сверяется с длительностью полной записи, а исключённые окна учитываются отдельно по причине исключения. Отсутствие ожидаемой строки не должно скрываться автоматическим заполнением без записи диагностического события.

В публикации результатов необходимо приводить состав классов, число независимых запусков по классам, число окон до и после фильтрации, критерии исключения и способ разделения выборки. Эти сведения позволяют оценивать, какие выводы относятся к свойствам классификатора, а какие могут быть следствием процедуры сбора данных. Описание аппаратной конфигурации и точки захвата необходимо в той степени, в какой они влияют на наблюдаемые статистики. Требование воспроизводимости не предполагает публикацию персональных идентификаторов или содержимого сообщений: при необходимости они обезличиваются с сохранением временной структуры и связности записей.

#### **5.4 Ограничения и условия применения результатов**

Представленные требования задают условия получения и преобразования сетевого трафика. Их соблюдение позволяет формировать размеченные наблюдения с известным происхождением меток, однако не гарантирует переносимости результатов на произвольные сети. Влияние фоновой нагрузки, изменений сетевого окружения и состава прикладных действий подлежит отдельной проверке.

При анализе матрицы статистических признаков необходимо учитывать распределения по классам, корреляции, выбросы и устойчивость признаков к изменению условий регистрации. Если состав признаков изменяется, требуется фиксировать версию схемы и повторно рассчитывать признаки для всех сопоставляемых наблюдений. Это условие обеспечивает согласованность входных данных при оценке моделей.

Вывод о сравнительной эффективности алгоритмов требует независимой проверки на общей выборке с одинаковым разделением по экспериментам. Наряду с усреднённой F1-мерой следует учитывать ошибки по каждому классу и время вычисления прогноза. Указанные условия ограничивают область применения теоретического сопоставления методов и предотвращают преждевременное утверждение о преимуществе отдельного классификатора.

## ЗАКЛЮЧЕНИЕ

В работе проанализированы методы формирования и классификации сетевого трафика с использованием машинного обучения. Рассмотрены свойства трафика как временного потока данных, уровни пакетного, потокового и оконного представления, основные группы статистических характеристик, а также факторы, способные исказить результаты классификации. Показано, что качество результата зависит от алгоритма, процедуры получения данных и достоверности разметки.

Проанализированы пассивный сбор реального трафика, использование открытых наборов данных, синтетическая генерация и сценарное формирование в программном стенде. При исследовании заданных режимов поведения определяющее значение имеют управляемость, воспроизводимость, возможность получения требуемых классов, достоверность эталонных меток и автоматическая разметка. По совокупности этих критериев обосновано использование сценарного программного стенда, формирующего клиент-серверные операции в контролируемой сети.

Проведён анализ способов разметки. Ручная и правило-ориентированная разметка имеют ограничения по масштабируемости или достоверности. При сценарном подходе источник трафика одновременно является источником эталонной временной метки: управляющая система знает момент запуска и окончания режима. Это позволяет автоматически назначать класс полным временным окнам независимо от признаков, которые позднее будет анализировать модель.

Сравнение форм представления показало целесообразность фиксированной оконной агрегации при сохранении PCAP как первичного источника. Для рассматриваемой задачи принято окно длительностью 1 с, обеспечивающее секундное временное разрешение при регистрации изменений интенсивности, числа соединений и структуры пакетов. Выбранная длительность фиксируется в схеме признаков и должна совпадать при обработке записанного трафика и классификации в потоковом режиме. Достаточность такого временного разрешения требует эмпирической оценки для конкретных классов.

Рассмотрены основные семейства методов машинного обучения: линейные, метрические, древесные, ансамблевые, опорновекторные, нейросетевые методы и методы обучения без учителя. Теоретические свойства не позволяют объективно ранжировать алгоритмы без экспериментальных данных. Для сопоставления методов определены поклассовые точность и полнота, усреднённая F1-мера, матрица ошибок и время вычисления прогноза при использовании единой матрицы признаков и независимых групп экспериментов.

Сформулированы требования к программному стенду и структуре набора данных. Для каждого эксперимента необходимо сохранять исходный PCAP, метаданные с временными границами и параметрами сценария, а также производный CSV с версией схемы признаков. Разделение обучающей и контрольной выборок выполняется по идентификаторам независимых экспериментов. Неполные или аварийные запуски исключаются из основного обучающего набора.

## Список литературы

- [1] Nguyen T. T. T., Armitage G. A Survey of Techniques for Internet Traffic Classification using Machine Learning // IEEE Communications Surveys & Tutorials. — 2008. — Vol. 10, no. 4. — P. 56–76. — DOI: 10.1109/SURV.2008.080406.
- [2] Moore A. W., Zuev D. Internet Traffic Classification Using Bayesian Analysis Techniques // ACM SIGMETRICS Performance Evaluation Review. — 2005. — Vol. 33, no. 1. — P. 50–60. — DOI: 10.1145/1064212.1064220.
- [3] Sharafaldin I., Lashkari A. H., Ghorbani A. A. Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization // Proceedings of ICISSP 2018. — 2018. — P. 108–116. — DOI: 10.5220/0006639801080116.
- [4] CSE-CIC-IDS2018 on AWS [Электронный ресурс]. — Canadian Institute for Cybersecurity. — URL: <https://www.unb.ca/cic/datasets/ids-2018.html> (дата обращения: 15.09.2026).
- [5] Eddy W. Transmission Control Protocol (TCP) // RFC 9293. — IETF, 2022. — DOI: 10.17487/RFC9293.
- [6] Postel J. User Datagram Protocol // RFC 768. — IETF, 1980. — DOI: 10.17487/RFC0768.
- [7] Claise B., Trammell B., Aitken P. Specification of the IP Flow Information Export (IPFIX) Protocol for the Exchange of Flow Information // RFC 7011. — IETF, 2013. — DOI: 10.17487/RFC7011.
- [8] Draper-Gil G., Lashkari A. H., Mamun M. S. I., Ghorbani A. A. Characterization of Encrypted and VPN Traffic Using Time-Related Features // Proceedings of ICISSP 2016. — 2016. — P. 407–414. — DOI: 10.5220/0005740704070414.
- [9] Erman J., Arlitt M., Mahanti A. Traffic Classification Using Clustering Algorithms // Proceedings of the 2006 SIGCOMM Workshop on Mining Network Data. — 2006. — P. 281–286. — DOI: 10.1145/1162678.1162679.
- [10] Rezaei S., Liu X. Deep Learning for Encrypted Traffic Classification: An Overview // IEEE Communications Magazine / arXiv preprint. — 2018. — arXiv:1810.07906.
- [11] Moustafa N., Slay J. UNSW-NB15: A Comprehensive Data Set for Network Intrusion Detection Systems // 2015 Military Communications and Information Systems Conference. — 2015. — P. 1–6. — DOI: 10.1109/MilCIS.2015.7348942.

- [12] The CAIDA UCSD Anonymized Internet Traces [Электронный ресурс]. — CAIDA. — URL: [https://www.caida.org/catalog/datasets/passive\\_dataset/](https://www.caida.org/catalog/datasets/passive_dataset/) (дата обращения: 15.09.2026).
- [13] MAWI Working Group Traffic Archive [Электронный ресурс]. — WIDE Project. — URL: <https://mawi.wide.ad.jp/mawi/> (дата обращения: 15.09.2026).
- [14] Tavallae M., Bagheri E., Lu W., Ghorbani A. A. A Detailed Analysis of the KDD CUP 99 Data Set // *Proceedings of the 2009 IEEE Symposium on Computational Intelligence for Security and Defense Applications*. — 2009. — P. 1–6. — DOI: 10.1109/CISDA.2009.5356528.
- [15] Баженов М. Д., Бусько М. М. Исследование достоверности обучающих наборов данных анализатора сетевого трафика // *System Analysis & Mathematical Modeling*. — 2025. — Т. 7, № 2. — С. 153–164. — DOI: 10.17150/2713-1734.2025.7(2).153-164.
- [16] Кононов Д. Д., Исаев С. В. Использование многоуровневых источников данных для подготовки обучающих наборов для обнаружения кибератак // *Программные системы: теория и приложения*. — 2025. — Т. 16, № 4. — С. 267–285. — DOI: 10.25209/2079-3316-2025-16-4-267-285.
- [17] Иванов С. О. Методика создания и обучения искусственной нейронной сети для решения задачи распознавания аномалий сетевого трафика // *Информационные технологии*. — 2024. — Т. 30, № 1. — С. 32–41. — DOI: 10.17587/it.30.32-41.
- [18] Koumar J., Hynek K., Pešek J., Čejka T. NetTiSA: Extended IP flow with time-series features for universal bandwidth-constrained high-speed network traffic classification // *Computer Networks*. — 2024. — Vol. 240. — Art. 110147. — DOI: 10.1016/j.comnet.2023.110147.
- [19] Cover T., Hart P. Nearest Neighbor Pattern Classification // *IEEE Transactions on Information Theory*. — 1967. — Vol. 13, no. 1. — P. 21–27. — DOI: 10.1109/TIT.1967.1053964.
- [20] Quinlan J. R. Induction of Decision Trees // *Machine Learning*. — 1986. — Vol. 1. — P. 81–106. — DOI: 10.1007/BF00116251.
- [21] Breiman L. Random Forests // *Machine Learning*. — 2001. — Vol. 45. — P. 5–32. — DOI: 10.1023/A:1010933404324.
- [22] Частикова В. А., Козачёк К. В., Коробская Е. С., Кравцов В. П. Обнаружение кибервторжений на основе сетевого трафика и поведения пользователя с использованием датасета UNSW-NB15 // *Известия ЮФУ. Технические науки*. — 2025. — № 5. — С. 229–243. — DOI: 10.18522/2311-3103-2025-5-229-243.

- [23] Friedman J. H. Greedy Function Approximation: A Gradient Boosting Machine // The Annals of Statistics. — 2001. — Vol. 29, no. 5. — P. 1189–1232.
- [24] Cortes C., Vapnik V. Support-Vector Networks // Machine Learning. — 1995. — Vol. 20. — P. 273–297. — DOI: 10.1007/BF00994018.
- [25] Югай П. Э. Исследование состязательных атак на классические модели машинного обучения в контексте обнаружения сетевых угроз // Проблемы информационной безопасности. Компьютерные системы. — 2025. — № 3. — С. 147–164. — DOI: 10.48612/jisp/xerr-dfhh-2zak.